George

Stack technique détaillé — Version privilégiant les solutions gratuites / open source

Document de référence technique — usage MVP / prototype

1. Ingestion & données de marché

- **yfinance** — Yahoo Finance, gratuit, pour le prototypage et les données historiques.
- **Alpha Vantage / Twelve Data** — API gratuites avec quota limité ; utile pour un MVP, pas pour suivre des milliers de titres en continu.
- **Redis Streams** — file de messages temps réel, gratuit en auto-hébergé (alternative à Kafka managé).
- **Apache Airflow** — open source, gratuit, pour les batches nocturnes et l'orchestration des collectes.

2. Stockage

- **PostgreSQL + TimescaleDB** — édition Community, gratuite en auto-hébergé, pour les séries temporelles OHLCV.
- **Redis** — open source, gratuit : cache et pub/sub d'alertes.
- **MinIO** — open source, gratuit : stockage objet compatible S3 pour les documents bruts collectés par les sous-agents.
- **pgvector** — extension PostgreSQL gratuite pour la recherche sémantique (alternative à un service vectoriel payant).

3. Moteur quantitatif

- **pandas, NumPy, pandas-ta** — indicateurs techniques, tous gratuits.
- **scikit-learn, XGBoost, LightGBM** — gratuits, pour le calcul du score de confiance.
- **vectorbt (édition open source) / Backtrader** — backtesting gratuit.

4. Orchestration des sous-agents

- **LangGraph / CrewAI** — open source, gratuits, pour l'orchestration multi-agents.
- **Celery + Redis** — gratuits, pour la file de tâches.
- **Playwright / Scrapy** — open source, gratuits, pour la collecte sur sources publiques.

5. LLM

Choix retenu pour le MVP : Mistral, via leur API gratuite (« La Plateforme »), avec quota — plutôt qu'un modèle auto-hébergé. Deux raisons : la qualité du français, éditeur français entraîné avec un vrai souci de la langue, cohérent avec un George qui doit expliquer son raisonnement en français ; et zéro infrastructure à gérer pour le prototype (pas de GPU, juste une clé API).

Alternative si le quota Mistral devient limitant : Groq (Llama 3.3 70B / Mixtral), pour la rapidité d'inférence — utile si les explications de George doivent être générées en quasi temps réel après une alerte.

Point de vigilance : le passage à un LLM propriétaire (Claude, GPT) sera probablement nécessaire pour la qualité d'explication visée par George en production, ce qui représente un coût à budgétiser plus tard.

6. Voix

- **Whisper (OpenAI)** — open source, gratuit en auto-hébergé, pour la reconnaissance vocale (speech-to-text).
- **Piper / Coqui TTS** — open source, gratuits, pour la synthèse vocale (alternative à ElevenLabs payant).

7. Backend

- **FastAPI** — gratuit, pour les API REST.
- **Authlib / FastAPI-Users** — open source, gratuits, pour l'authentification.

8. Frontend

- **React + Tailwind** — gratuits.
- **Recharts / TradingView Lightweight Charts** — open source, gratuits, pour les graphiques.

9. Infrastructure

- **Docker + Kubernetes** — logiciels gratuits — l'hébergement sous-jacent reste payant (voir point de vigilance ci-dessous).
- **GitHub Actions** — gratuit dans la limite du quota mensuel.
- **Prometheus + Grafana** — open source, gratuits, pour l'observabilité.
- **Let's Encrypt** — certificats TLS gratuits.

10. Gestion des logs

Deux catégories de logs coexistent chez George, avec des exigences et une gestion très différentes.

Logs d'audit métier (dans PostgreSQL, jamais purgés automatiquement)

Tout ce qui doit rester interrogeable, fiable et durable — décisions, patterns détectés, provenance des sous-agents, mises en quarantaine — vit en base relationnelle, pas dans des fichiers texte qui tournent.

- **decisions / decision_outcomes / patterns_detected** — traçabilité complète des choix de George et de leurs résultats.
- **produced_by_agent** — identifiant du sous-agent responsable de chaque donnée collectée (modèle de responsabilité par sous-agent).
- **Table de quarantaine** — informations collectées non validées, conservées et consultables plutôt que supprimées.

Ces données ne sont jamais purgées automatiquement : elles alimentent la mémoire historique et l'apprentissage continu. Les supprimer reviendrait à amputer George de son expérience accumulée.

Logs techniques (debug, performance, sécurité)

- **Format structuré JSON** — avec un trace_id par décision ou tâche de sous-agent (OpenTelemetry, gratuit), pour reconstituer le parcours complet : détection → collecte → décision → alerte.
- **Agrégation centralisée** — Grafana Loki + Promtail (gratuits, open source), plus léger qu'un stack ELK complet, et déjà cohérent avec Grafana prévu pour l'observabilité.
- **Rotation locale** — logrotate si nécessaire en complément, l'essentiel étant expédié directement vers Loki.
- **Rétention différenciée** — logs techniques courants conservés 30 à 90 jours ; logs de sécurité (authentification, accès refusés) conservés plus longtemps à des fins d'audit.
- **Commandes vocales** — transcription et action décidée loguées spécifiquement, pour permettre un audit en cas d'erreur de reconnaissance.

Ce qui n'est jamais logué en clair : mots de passe, tokens, clés API — conformément aux exigences de sécurité posées dès la phase de conformité.

Point de vigilance

« Gratuit » concerne les licences logicielles, pas l'infrastructure : héberger PostgreSQL, Kubernetes, Airflow, etc. nécessite quand même des serveurs (cloud ou on-premise), qui restent un coût réel. De même, les API de données de marché gratuites ont des quotas et de la donnée différée — suffisant pour un prototype ou un test comme celui réalisé sur le marché français, mais pas pour une version en production sur plusieurs milliers de titres en temps réel.